



**Optimisez la gestion des données
d'une boutique avec R ou Python**

Contexte :

La gestion des données de ventes et de stock repose initialement sur des outils artisanaux (fichiers Excel, traitements manuels), rendant l'analyse complexe, chronophage et sujette aux erreurs.

Objectif du projet :

Passer d'une gestion artisanale des données à une analyse structurée, automatisée et fiable, afin d'améliorer la qualité des données, faciliter la prise de décision et optimiser la gestion des stocks et des performances commerciales.

Outils utilisés :

Python (pandas, numpy, matplotlib, seaborn, plotly express)

Sources de données :

ERP : informations produits, prix, coûts, stocks

LIAISON : correspondance product_id ↔ id_web

WEB : informations issues du site e-commerce (sku, ventes, attributs produits)

Analyses Exploratoires des Données ERP

Dataset analysé :

- Fichier : ERP
- Variables : stock_quantity, stock_status (instock, outofstock)

Caractéristiques :

- ❑ Incohérences entre la quantité en stock et le statut stock
- ❑ Présence de quantités de stock négatives, incompatibles avec une gestion normale des stocks (erreurs de saisie ou de synchronisation)

Traitements réalisés :

- Application d'une règle métier :
 $\text{stock_quantity} \leq 0 \rightarrow \text{outofstock}$
 $\text{stock_quantity} > 0 \rightarrow \text{instock}$
- Identification et suppression des stocks négatifs, sauvegardées dans « df_erp_stock_quantity_neg (traçabilité) »

Remarques:

- ❖ Leur exclusion permet de garantir la fiabilité des analyses de stock et de rotation

Analyses Exploratoires des Données ERP

Dataset analysé :

- Fichier : ERP
- Variables : price, purchase_price

Caractéristiques :

- ❑ Présence de prix négatifs, incompatibles avec une logique de vente classique (erreurs de saisie ou de paramétrage)
- ❑ Présence de prix de vente inférieurs au coût d'achat, générant des incohérences économiques et des marges négatives non réalistes

Traitements réalisés :

- Suppression des lignes présentant un prix négatif, sauvegardées dans « df_erp_price_neg (traçabilité) »
- Conversion des prix de vente en hors taxes (HT) avant comparaison
- Exclusion des prix de vente inférieurs au coût d'achat, sauvegardés dans «df_prix_incoherent (traçabilité)»

Remarques:

- ❖ Leur exclusion permet d'éviter de biaiser les analyses de marge et de rentabilité

Analyses Exploratoires des Données WEB

Dataset analysé :

- Fichier : WEB
- Variables : sku (Stock Keeping Unit)(un identifiant unique produit)

Caractéristiques :

- ☐ Présence de doublons SKU, liés à des lignes techniques correspondant aux images produits
- ☐ Les lignes sans sku sont massivement non renseignées sur les variables métier, exemples :price, total_sales, certaines colonnes sont totalement vides, les colonnes techniques sont renseignées par défaut

Traitements réalisés :

- Exclusion des doublons SKU, sauvegardés dans « df_web_type_image (traçabilité) »
- Exclusion des lignes sans SKU , sauvegardés dans « df_sans_sku (traçabilité) »

Remarques:

- ❖ Le nettoyage a permis de rétablir l'unicité des SKU
- ❖ Le jeu de données est désormais cohérent et exploitable pour les jointures et analyses ultérieures

Analyses Exploratoires des Données LIAISON

Dataset analysé :

- Fichier : LIAISON
- Variables : id_web, product_id

Caractéristiques :

- ❑ 91 produits présents dans l'ERP ne disposent d'aucune correspondance avec le catalogue web (produits hors ligne, non publiés ou non synchronisés)

Traitements réalisés :

- Identification et suppression des produits sans correspondance web, sauvegardées dans « df_liaison_sans_correspondance (traçabilité) »

Remarques:

- ❖ Leur exclusion permet de garantir la cohérence des jointures et des indicateurs calculés

Fusion ou consolidations des données

Choix des attributs :

Données issues des fichiers ERP, LIAISON et WEB

Clés de jointure utilisées :

- product_id pour la jointure (ERP - LIAISON)
- id_web/sku pour la jointure (ERP - LIAISON) - (WEB)

Méthode de fusion :

- Une fusion interne (inner join) est utilisée pour construire le jeu de données principal d'analyse :
Elle supprime automatiquement les lignes sans correspondance entre les fichiers, garantissant un jeu de données cohérent et exploitable
- Une fusion externe (outer join avec indicateur) est utilisée uniquement à des fins de contrôle :
Identification des lignes sans correspondance

Vigilances et décisions:

- ❖ Seules les données correctement appariées sont conservées pour les analyses finales

Analyses univariées du prix


Méthodes statistiques employées :

« Mesure de dispersion à l'aide de l'intervalle interquartile (IQ) »

Méthode robuste, adaptée aux distributions asymétriques et aux valeurs extrêmes, fréquentes dans les données e-commerce, contrairement au **Z-score** qui suppose une distribution normale

Graphique avec commentaire des résultats :

- Forte asymétrie à droite
- Présence de produits à prix élevés dans le catalogue



Limites éventuelles de l'analyse :

- ❖ Le nombre d'articles identifiés comme outliers en prix est 31, représentent une faible proportion du catalogue (4,35 %)
- ❖ Leur niveau de prix élevé peut s'expliquer par des caractéristiques produits spécifiques (gamme premium, rareté, format)

Analyses univariées du prix


Méthodes statistiques employés :

« Mesure de dispersion à l'aide de l'intervalle interquartile (IQ) »

Graphique avec commentaire des résultats :

- Graphique des 10 produits les plus chers du catalogue
- Les niveaux de prix observés sont cohérents avec des produits hauts de gamme

Affichage de 10 outliers



Limites éventuelles de l'analyse :

- ❖ Les outliers détectés correspondent à des produits premium réels confirmé par une vérification sur des sites web
- ❖ Il s'agit d'outliers statistiques et non d'anomalies métier, ils ont donc été conservés dans l'analyse

Grand cru millesime 2008 75cl

Le champagne Grand Cru millesime 2008 de la maison EGLY-OURIET est l'un des meilleurs vins de la région de Reims, classé Grand Cru.

en savoir plus

356€

● **Attention**

Ce produit est définitivement épuisé.

Découvrir les Champagnes Egly-ouriet

✓ Livraison en point Relais disponible

vue en ligne / Vins / Vins rares / David Duband Charmes-Chambertin Grand Cru 2014

David Duband Charmes-Chambertin Grand Cru 2014

217,50€ TTC **EN STOCK**

Robe cerise chatoyante. Un nez de fruits rouges et noirs avec une dynamique aromatique de poivre. Une fine touche de bois de santal. La bouche est riche et grasse avec des tanins présents et riches qui augurent un très beau potentiel de garde.

- 1 +

Ajouter au panier


Domaine

Analyse des ventes en CA

Le chiffre d'affaires total s'élève à **143 324,1 €**

Graphique en barre des 20 premiers articles avec plotly express

Top 20 des articles par chiffre d'affaires




La répartition Pareto des ventes en CA

Méthodes statistiques employés :

- Application de la loi de Pareto (20/80)

Graphique avec commentaire des résultats :

- 433 articles (61 % du catalogue) génèrent 80 % du chiffre d'affaires, ce qui montre une répartition du CA relativement diffuse et non fortement concentrée sur quelques produits



Limites éventuelles de l'analyse :

- ❖ La loi de Pareto n'est pas vérifiée
- ❖ Une large part du catalogue contribue au CA global

Analyse des ventes en quantité

Graphique en barre des 20 premiers articles avec plotly express

Top 20 des articles en quantité vendues




La répartition pareto des ventes en quantité

Méthodes statistiques employés :

- Application de la loi de Pareto (20/80)

Graphique avec commentaire des résultats :

- 61 % des articles sont nécessaires pour atteindre 80 % des volumes vendus



Limites éventuelles de l'analyse :

- ❖ Les ventes reposent sur un large assortiment de produits
- ❖ La loi de Pareto n'est pas vérifiée

Analyse des stocks

Méthodes statistiques employés :


- Calcule de la rotation de stock (nombre de mois nécessaires pour écouler le stock), basée sur les ventes observées en octobre
- Calculée uniquement pour les produits ayant enregistré des ventes positives
- Les valeurs infinies ou non interprétables sécurisées ou exclues

Limites éventuelles de l'analyse :

- ❖ Le champagne apparaît en surstock
- ❖ Une des hypothèses de ce surstock l'anticipation des ventes de fin d'année

Graphique avec commentaire des résultats :

- Les durées d'écoulement vont d'environ de 14 à plus de 30 mois
- Une part importante des produits concernés correspond au champagne




Analyse du taux de marge

Méthodes statistiques employés :

- $\text{Taux de marge} = (\text{Prix HT} - \text{Cout d'achat}) / \text{Cout d'achat}$
- Évaluer la rentabilité permet d'identifier les produits déficitaires, peu rentables ou à forte marge

Graphique avec commentaire des résultats :



- Cognac, Whisky, Gin sont les plus rentables
- Le Vin conserve une bonne rentabilité mais avec une pression concurrentielle plus forte
- L'huile d'olive et champagne sont à faible marge

Limites éventuelles de l'analyse :


- ❖ Aucun produit à marge négative → qualité du nettoyage confirmée
- Marges observées : min 29 % – max 91 %
- ❖ L'ensemble des produits analysés est rentable

Analyse des corrélations entre les variables stock, sales et price

Méthodes statistiques employés :

- Corrélations linéaires (coefficient de Pearson)
- Mesure la relation linéaire entre variables quantitatives

Graphique avec commentaire des résultats :



Limites éventuelles de l'analyse :

- ❖ Le prix influence significativement les ventes, tandis que le stock est logiquement lié aux volumes écoulés
- ❖ Ces résultats fournissent des indicateurs utiles pour piloter les décisions commerciales, avec prudence dans leur interprétation

- Stock ↔ Ventes : corrélation positive modérée ($\sim 0,45$) → Plus de stock est généralement associés à plus de ventes
- Prix ↔ Ventes : corrélation négative modérée ($\sim -0,52$) → Les produits plus chers se vendent globalement moins
- Prix ↔ Stock : corrélation très faible négative ($\sim -0,10$) → Le prix n'a quasiment pas de lien avec le niveau de stock

Recommandations pour la mise en place de l'ERP

- Mettre en place des règles de contrôle automatiques (stocks négatifs, prix incohérents, statuts stock)
- Garantir une liaison fiable ERP – Web (unicité des SKU, correspondance produits)
- Intégrer la saisonnalité des ventes dans la gestion des stocks (ex. anticipation du champagne)
- Suivre des indicateurs clés directement dans l'ERP : rotation de stock, CA, marges
- Utiliser l'ERP comme outil d'aide à la décision pour le pilotage commercial et logistique

Point sur les compétences apprises



- *QU'EST-CE QUI S'EST BIEN PASSÉ POUR VOUS DANS CE TRAVAIL DE NETTOYAGE ?*
NETTOYAGE DES DONNÉES, LOGIQUE MÉTIER, STRUCTURATION DES TRAITEMENTS
- *QU'EST-CE QUE VOUS AVEZ TROUVÉ LE PLUS DIFFICILE ?*
CONCEPTS STATISTIQUES ET INTERPRÉTATION MATHÉMATIQUE
- *SUR QUELLES TÂCHES EST-CE QUE VOUS PENSEZ AVOIR BESOIN DE PLUS D'ENTRAÎNEMENT ?*
STATISTIQUES, INTERPRÉTATION ÉCONOMIQUE, VISUALISATION