


Analyse de l'évolution des profils sociodémographiques des étudiants OpenClassrooms

*Pipeline de transformation de données avec **dbt***



Contexte du projet



Objectif du projet :

Analyser l'évolution du profil sociodémographique des étudiants inscrits aux parcours Data sur 4 ans chez OpenClassrooms, afin d'identifier plusieurs tendances et d'alimenter les réflexions stratégiques de l'entreprise sur l'accessibilité et l'égalité des chances

Entreprise:

OpenClassrooms est une école 100% en ligne qui permet à des milliers d'individus partout dans le monde de développer leurs compétences professionnelles et de se former aux métiers de demain

Outils utilisés :

- Snowflake
- dbt (Data Build Tool)
- SQL
- Excel
- Github

Respect du RGPD

Les données ont été traitées en respectant les principes du RGPD (Règlement Général sur la Protection des Données).

Les identifiants des étudiants ont été pseudonymisés afin de protéger les données personnelles.

Les identifiants originaux ont été remplacés par des valeurs pseudonymisées dans la couche staging, ce qui permet de sécuriser les données tout en conservant la possibilité d'effectuer des analyses.

Par ailleurs :

- aucune donnée personnelle directement identifiable n'est utilisée
- les analyses sont réalisées uniquement sur des variables agrégées telles que l'âge, le genre et la région

Méthodologie de collecte

La méthodologie repose sur une architecture de pipeline de données comprenant la collecte, la transformation et l'analyse des données

Le projet est structuré en 4 étapes principales :

Etape 1 : Collecte des données

Etape 2 : Chargement des données dans Snowflake

Etape 3 : Transformation des données avec dbt

Etape 4 : Analyse et valorisation des données



Etape 1 : Collecte des données



Objectif :

Récupérer les données nécessaires à l'analyse des profils sociodémographiques des étudiants

Sources de données :

- Données internes : données des étudiants inscrits dans les parcours Data de 2022 à 2025
- Données publiques : données démographiques INSEE
(<https://www.insee.fr/fr/statistiques/8721456>)

Contenu des données démographiques

Les fichiers CSV contiennent :

- ☐ Estimations de la population
- ☐ Répartition par région
- ☐ Genre
- ☐ Tranches d'âge

Etape 2 : Chargement des données dans Snowflake



Organisation des données :

Les données INSEE ont été chargées dans 4 tables, chaque table correspondant à une année d'observation

Méthode utilisée : ELT

Les données sont chargées brutes dans le data Warehouse **Snowflake** en appliquant la méthode **ELT** (Extract, Load, Transform) afin de conserver l'intégralité des informations originales

Mon espace de travail > population_2022.sql

ACCOUNTADMIN - COMPUTE

```
1 SELECT
2 *
3 FROM
4 "DATASET_DBT"."RAW"."POPULATION_2022"
```

Résultats (à l'instant)

	C1	C2	C3	C4	C5
1	Estimation de population au 1er janvier, par région, sexe et âge	null	null	null	null
2	Année 2022	null	null	null	null
3	null	null	null	null	null
4	Régions	Ensemble	null	null	null
5	null	0 à 4 ans	5 à 9 ans	10 à 14 ans	15 à 19 ans
6	Auvergne-Rhône-Alpes	434 649	492 463	515 533	502 055
7	Bourgogne-Franche-Comté	134 650	156 098	168 421	166 360
8	Bretagne	164 506	190 870	211 480	208 531
9	Centre-Val-de-Loire	129 585	149 846	162 040	155 539
10	Corse	16 107	17 967	18 908	17 560
11	Grand Est	273 168	313 760	335 080	334 137
12	Hauts-de-France	328 128	381 165	404 180	396 743
13	Île-de-France	735 678	783 391	801 089	779 479
14	Normandie	169 021	194 364	209 596	205 182
15	Nouvelle-Aquitaine	273 575	319 038	350 435	347 557
16	Occitanie	289 909	332 184	357 832	359 520
17	Pays de la Loire	200 075	231 682	253 344	250 096
18	Provence-Alpes-Côte d'Azur	254 458	284 647	299 106	286 532
19	France métropolitaine	3 403 509	3 847 475	4 087 044	4 009 291
20	Guadeloupe	18 513	21 520	24 132	25 543
21	Martinique	16 084	18 589	20 960	21 056

Mon espace de travail > afficher_dataset_dbt.sql

ACCOUNTADMIN - COMPUTE

```
1 select * from "DATASET_DBT"."RAW"."ORDERS"
```

Résultats (il y a 2 minutes)

	USER_ID	PATH_CATEGORY_NAME	AGE_GROUP	GENDER
1	U-4510146189133097827	Data	30-34 ans	F
2	U-3523981388172716996	Data	60 ans ou plus	M
3	U-554277309782049638	Data	30-34 ans	null
4	U682607025763480308	Data	50-54 ans	null
5	U437613285573805637	Data	25-29 ans	M
6	U-4482262213744839422	Data	40-44 ans	M
7	U-2562732802084378413	Data	35-39 ans	F
8	U-6176528868810385931	Data	45-49 ans	M
9	U-1954461118288915668	Data	30-34 ans	M
10	U4330436167950632396	Data	25-29 ans	M
11	U8742999110400778647	Data	25-29 ans	null
12	U-1036823501391385032	Data	30-34 ans	M
13	U8409395407151835600	Data	30-34 ans	null
14	U7285653395317318525	Data	40-44 ans	null
15	U-2577037013509769842	Data	50-54 ans	null
16	U-670599522568599860	Data	40-44 ans	null
17	U-5012470742624196991	Data	30-34 ans	M
18	U-2285790741378855668	Data	45-49 ans	F
19	U7333026495563049637	Data	40-44 ans	F
20	U3108149232846304046	Data	25-29 ans	M
21	U5449854078891567249	Data	25-29 ans	M
22	U-2579201481824761196	Data	25-29 ans	M
23	U-278676107479710477	Data	35-39 ans	F

Etape 3 : Transformation des données avec dbt - Staging




Trois types de modèles dbt sont utilisés dans le pipeline de transformation :

1. Modèle Staging : Permet de nettoyer les données brutes

Principales transformations :

- Conversion des valeurs texte en numériques
- Suppression des caractères inutiles
- Normalisation des noms de régions
- Gestion des valeurs manquantes
- Pseudonymisation des identifiants utilisateurs



```
1 {{config(materialized='view')}}
2 -- Modèle de staging : nettoyage et préparation des données étudiants
3 select
4   -- Pseudonymisation de l'identifiant utilisateur pour protéger les données personnelles
5   sha2(cast(user_id as string), 256) as user_id,
6   path_category_name,
7   age_group,
8   -- Remplacement des valeurs nulles dans le genre par "unknown"
9   coalesce(gender, 'unknown') as gender,
10  -- Normalisation des noms de régions pour garantir une cohérence
11  case when region = 'Centre-Val de Loire' then 'Centre-Val-de-Loire'
12        when region = 'DROM' then 'DOM'
13        else region end as region,
14  year_path_started
15 from [source('ecommerce', 'orders')]
```


Etape 3 : Transformation des données avec dbt - Intermediate



2. Modèle Intermediate : Permet de structurer et enrichir les données pour faciliter l'analyse

Principales transformations :

- UNPIVOT des colonnes d'âge pour transformer les données en format analytique
- Regroupement des tranches d'âge (60 ans ou plus)
- Agrégation de la population
- Union des tables population 2022, 2023, 2024 et 2025



```
1  {{ config(materialized='view') }}
2  select * from {{ ref('int_population_2022_enriched') }}
3
4  union all
5
6  select * from {{ ref('int_population_2023_enriched') }}
7
8  union all
9
10 select * from {{ ref('int_population_2024_enriched') }}
11
12 union all
13
14 select * from {{ ref('int_population_2025_enriched') }}
```

Etape 3 : Transformation des données avec dbt - Marts




3. Modèle Marts :

Permet de créer la table finale d'analyse

Cette table finale permet de :

- Comparer le profil des étudiants avec la population générale
- Créer des indicateurs d'analyse
- Faciliter la visualisation des résultats



	USER_ID	PATH_CATEGORY_NAME	AGE_GROUP	GENDER	REGION	YEAR_PATH_STARTED	ESTIMATION_POPULATION
1	9c9f55cfc3ca8775049e8c1aafea450a00703ad4df5132	Data	30-34 ans	F	Île-de-France	2025	454134
2	c26f2ae2be1b2cfad9568e7f395d3d8deb0f8b2e3d2b964	Data	60 ans ou plus	M	Île-de-France	2023	1166390
3	9b9b783962c1f63dd590ea829898d29511820112270d	Data	30-34 ans	unknown	Hauts-de-France	2023	null
4	2a3e777715e437f670001588e0d631a2f6aba311968	Data	50-54 ans	unknown	Île-de-France	2023	null
5	d951ec487634e5193434a7d85a1dfc6ff88619c29eb55	Data	25-29 ans	M	Hauts-de-France	2025	170392
6	5ece949315a1b7233f30903898bcc8927bba02a2ddccc	Data	40-44 ans	M	Auvergne-Rhône-	2025	262919
7	73dcf22712dac5ed82774ad7f604bb79eb7cbcb766c8b4	Data	35-39 ans	F	Île-de-France	2023	451589
8	2eae90422e4e0123610535aeb3baf90a0cef65ed5615	Data	45-49 ans	M	Île-de-France	2024	403588
9	5716f743821351a84c54c4cd31ae43c8e3e6da7ffc7b7	Data	30-34 ans	M	Centre-Val-de-Loi	2022	70117
10	770196a3e5c5f6ef7f89d84eacf26ef3bcb315e89def229	Data	25-29 ans	M	Île-de-France	2024	427506
11	0d87ef5fc8137a2e93b2a3a98333f73631400fde5df1b	Data	25-29 ans	unknown	Île-de-France	2023	null
12	0519b8fc94f8857b95e268b3e507b8fc562906aa4dc17	Data	30-34 ans	M	Île-de-France	2025	434199

```
-- Modèle final (mart)
-- Ce modèle combine les données enrichies des étudiants
-- avec les estimations de population pour permettre
-- des analyses comparatives par région, âge, genre et année.
select
  e.user_id,
  e.path_category_name,
  e.age_group,
  e.gender,
  e.region,
  e.year_path_started,
  p.estimation_population
from {{ ref('int_etudiant_enriched') }} e
left join {{ ref('int_population_all_years') }} p
  on e.region = p.region
  and e.gender = p.gender
  and e.age_group = p.age_group
  and e.year_path_started = p.year_path_started
```

Tests de qualité des données



```
DbtPropertiesFile (dbt_yml_files-latest-fusion.json)
version: 2
models:
  - name: stg_etudiant
    description: Modèle de staging contenant les données nettoyées des étudiants
    columns:
      - name: user_id
        description: Identifiant pseudonymisé de l'étudiant. Peut apparaître plusieurs fois selon l'année ou la formation.
        data_tests:
          - not_null # Vérifie que l'identifiant n'est jamais vide
      - name: gender
        description: Genre de l'étudiant
        tests:
          - accepted_values:
              arguments:
                values: ['F', 'M', 'unknown'] # Vérifie que seules ces valeurs sont possibles
      - name: year_path_started
        description: Année de début du parcours de formation de l'étudiant
        tests:
          - accepted_values:
              arguments:
                values: [2022, 2023, 2024, 2025] # Vérifie que seules les années présentes dans les données sources sont utilisées
```

```
1 -- Test d'unicité des identifiants étudiant par année
2 -- La combinaison (user_id, year_path_started) doit être unique
3 select
4     user_id,
5     year_path_started,
6     count(*) as nb
7 from {{ ref('stg_etudiant') }}
8 group by 1, 2
9 -- Si le nombre est supérieur à 1, cela signifie qu'il existe des doublons
10 -- Dans ce cas le test échoue
11 having count(*) > 1
```


```
1 -- Test de validation des valeurs de la colonne age_group
2 -- Ce test vérifie que toutes les valeurs de age_group appartiennent
3 -- à la nomenclature attendue des tranches d'âge.
4 select * from {{ref('stg_etudiant')}}
5 where age_group is not null
6 and age_group not in (
7     '20-24 ans',
8     '25-29 ans',
9     '30-34 ans',
10    '35-39 ans',
11    '40-44 ans',
12    '45-49 ans',
13    '50-54 ans',
14    '55-59 ans',
15    '60 ans ou plus'
16 )
```

Etape 4 : Analyse et valorisation des données




Création des indicateurs calculés :

❑ Répartition des étudiants par genre




❑ Répartition par tranche d'âge




Etape 4 : Analyse et valorisation des données




❑ Répartition par région



❑ Evolution du nombre d'étudiant par année




❑ Évolution de la répartition des étudiants par genre




Etape 4 : Analyse et valorisation des données



□ Evolution par tranche d'âge



□ Comparaison avec la population





Interprétation des résultats

- ✓ La forte présence des 25-39 ans peut refléter des parcours de reconversion ou d'évolution professionnelle.
- ✓ La concentration en Île-de-France s'explique probablement par la forte présence d'établissements et d'opportunités professionnelles.
- ✓ La baisse entre 2022 et 2024 peut être liée à des facteurs économiques ou à des variations dans l'offre de formation.
- ✓ La stabilité des proportions indique un déséquilibre de genre persistant dans ces formations.
- ✓ Certaines régions montrent une participation plus forte aux formations par rapport à leur population.

Conclusion et recommandations

- ❖ L'analyse met en évidence des disparités dans la répartition des étudiants selon le genre, l'âge et la région.
- ❖ Il serait pertinent de renforcer l'accès aux formations dans les régions moins représentées, d'encourager une meilleure diversité dans les parcours de formation et de poursuivre le suivi des indicateurs afin d'anticiper les évolutions et adapter l'offre de formation.