

Projet N°9 : Analysez les ventes d'une librairie avec R ou Python

Contexte du projet

Objectif du projet :

- Réaliser une analyse globale des indicateurs clés de l'entreprise afin comprendre la performance commerciale de l'entreprise et d'identifier des pistes d'action pour améliorer le chiffre d'affaires

Entreprise:

- Lapage est une librairie initialement physique disposant de plusieurs points de vente.
Face au succès de certains produits et à la demande croissante des clients, elle a ouvert il y'a 2 ans un site de vente en ligne

Outils utilisés :

- Python


Etapas d'analyse

Partie 1 : Analyse descriptive des indicateurs de ventes

Objectif : Analyser les différents indicateurs de vente pour comprendre la performance globale de l'entreprise

- ▶ 1. Évolution du chiffre d'affaires
- ▶ 2. Évolution du nombre de clients
- ▶ 3. Évolution du nombre de transactions
- ▶ 4. Top client
- ▶ 5. Top/flop produit
- ▶ 6. Répartition par catégorie
- ▶ 7. Répartition par âge
- ▶ 8. Courbe de Lorenz

► Partie 1.1 : Évolution dans le temps du CA avec moyenne mobile




Analyse :

- Le CA journalier est très variable
- La moyenne mobile met en évidence deux pics autour d'octobre 2021 et mars 2022
- Deux baisses sont observées après ces pics
- La tendance générale reste stable

Conclusion :

L'activité commerciale reste globalement stable dans le temps, malgré quelques fluctuations ponctuelles.

► Partie 1.1 : Évolution dans le temps du CA par catégorie



Analyse :

- La catégorie 1 génère le CA le plus élevé
- La catégorie 0 est intermédiaire
- La catégorie 2 reste la moins performante
- Un pic est observé pour la catégorie 1 fin 2021-début 2022

Conclusion :

La catégorie 1 est la plus contributrice au CA, les catégories 0 et 2 offrent un potentiel d'amélioration.

► Partie 1.2 : Évolution mensuelle du nombre de clients




Analyse :

- Le nombre de clients est globalement stable entre 5600 et 5800, sur la majorité de la période
- Un pic apparaît en octobre 2021, proche de 6 200 clients
- Une baisse nette est observée sur le dernier mois

Conclusion :

Le pic de clients observé en octobre 2021 coïncide avec celui du chiffre d'affaires, ce qui suggère un lien entre hausse de la clientèle et hausse des ventes. Il peut toutefois aussi s'expliquer par des effets saisonniers, promotionnels ou par une hausse du panier moyen.

► Partie 1.3 : Évolution mensuelle du nombre de transactions



Analyse :


► Un creux apparaît en juillet 2021, suivi de deux pics en fin 2021 atteignant environ 33 000 transactions

► La tendance se stabilise ensuite en 2022, avant une baisse sur le dernier mois observé.

Conclusion :

Le pic des transactions en fin 2021 coïncide avec celui du nombre de clients et du chiffre d'affaires, suggérant une hausse globale de l'activité commerciale.

► Partie 1.4 : Top 10 des clients par CA




Analyse :

- Quatre clients (c_1609, c_4958, c_6714 et c_3454) génèrent un chiffre d'affaires nettement supérieur à celui des autres clients
- Une fois ces clients exclus, le chiffre d'affaires des autres meilleurs clients devient plus équilibré et plus homogène

Conclusion :

On peut donc considérer que ces quatre clients relèvent d'un profil **BtoB**, alors que le reste de la clientèle correspond davantage à un profil **BtoC**.

► **Partie 1.5 : Top / flop produit**





Analyse :

- Quelques produits concentrent l'essentiel du chiffre d'affaires
- Les produits du flop 10 ont une contribution très faible aux ventes

Conclusion :

La performance produit est inégale : certains produits sont moteurs, tandis que d'autres restent peu rentables.

► **Partie 1.6 : Répartition par catégorie du CA et prix moyen**





Analyse :

- La catégorie 1 réalise le chiffre d'affaires le plus élevé, avec un prix moyen modéré
- La catégorie 2 est la plus chère, mais son chiffre d'affaires reste plus faible, ce qui suggère un volume de ventes inférieur

Conclusion :

Le chiffre d'affaires ne dépend donc pas uniquement du prix, mais aussi de la quantité vendue.

► Partie 1.7 : Répartition par âge des clients et panier moyen



Analyse :


Le croisement des deux graphiques fait apparaître trois profils :

- moins de 35 ans : moins nombreux, mais panier moyen plus élevé
- 35 à 55 ans : les plus nombreux, avec un panier moyen intermédiaire
- plus de 55 ans : moins nombreux, avec un panier moyen plus faible


Conclusion :

Les moins de 35 ans dépensent davantage par achat, tandis que les 35–55 ans représentent la majorité des clients.

► Partie 1.8 : Courbe de Lorenz du CA par client



```
1 # Gini = 0 : égalité parfaite
2 AUC = (lorenz.sum() -lorenz[0])
3 S = 0.5 - AUC # surface entre
4 gini = 2*S
5 gini
np.float64(0.44189587995615665)
```



```
1 # Gini = 0 : égalité parfaite
2 AUC = (lorenz.sum() -lorenz[0])
3 S = 0.5 - AUC # surface entre
4 gini = 2*S
5 gini
np.float64(0.39828603507456617)
```

Analyse :

- Le premier graphique présente une cassure nette, signe d’une forte concentration du CA
- Cette cassure disparaît sur le deuxième graphique après retrait des 4 clients BtoB
- Le CA des clients BtoC apparaît plus homogènement réparti
- Cette évolution est confirmée par l’indice de Gini, qui diminue de 0,44 à 0,40

Conclusion :

Les 4 clients BtoB accentuent fortement la concentration du chiffre d’affaires, alors que la clientèle BtoC présente une distribution plus équilibrée.

Etapas d'analyse

Partie 2 : Analyse bivariée centrée sur les clients


Objectif : Etudier les relations entre les caractéristiques des clients et leurs comportements d'achat

- ▶ 1. Genre du client et catégories de livres achetés
- ▶ 2. Age des clients et le montant total des achats
- ▶ 3. Age des clients et la fréquence d'achat
- ▶ 4. Age des clients et panier moyen
- ▶ 5. Age des clients et la catégorie des livres achetés

► **Partie 2.1 : Lien entre le genre du client et la catégorie de livres achetés (2 variables qualitatives)**

Tableau de contingence

categ	0	1	2
sex			
f	200793	115721	16980
m	186488	104884	15868



Le Test de Chi-2 a été choisi car les fréquences attendues sont toutes supérieures à 5

Hypothèses du test

H0 : le sexe et la catégorie achetée sont indépendants

H1 : le sexe et la catégorie achetée sont dépendants

Test du Chi-2

```
Statistique Chi-2: 22.66856665178056
Valeur p: 1.1955928116587024e-05
Degrés de liberté: 2
Fréquences attendues:
[[201574.89662481 114822.13191434 17096.97146086]
 [185706.10337519 105782.86808566 15751.02853914]]
```


Analyse :

- Visuellement, les différences entre genres sont faibles
- $p\text{-value} < 0,05 \rightarrow$ on rejette H0
- Le test du Chi-2 révèle une dépendance statistiquement significative

Conclusion :

Même si la liaison est peu visible graphiquement, elle existe bien sur le plan statistique.

► Partie 2.2 : Corrélation entre l'âge des clients et le montant total des achats (2 variables quantitatives)



Hypothèses du test

H0 : il n'existe pas de corrélation entre l'âge et le montant total des achats

H1 : il existe une corrélation entre l'âge et le montant total des achats

Test de Spearman

```
Coefficient de corrélation de Spearman: -0.8744497607655503  
Valeur p: 5.956077505475151e-25
```

Analyse :


- Le montant total des achats augmente jusqu'à 50 ans, puis baisse
- Le coefficient de Spearman (-0,87) confirme une forte relation négative
- La p-value très faible montre que cette corrélation est significative

La relation n'étant pas linéaire, le test de Spearman a été privilégié.

Conclusion :

L'âge influence donc significativement le montant total des achats, avec une tendance globale décroissante

► Partie 2.3 : Corrélation entre l'âge et la fréquence d'achat (2 variables quantitatives)



Spearman a été choisi car la relation n'est pas linéaire, ce qui rend Pearson moins adapté.

Hypothèses du test

H0 : il n'existe pas de corrélation entre l'âge et la fréquence d'achats

H1 : il existe une corrélation entre l'âge et la fréquence d'achats

Test de Spearman

```
Coefficient de corrélation de Spearman: -0.6593848257006152  
Valeur p: 9.36237939303452e-11
```

Analyse :

- Hausse de la fréquence d'achat jusqu'à 50 ans, puis baisse
- Spearman confirme une corrélation négative modérée et significative
- P-value < 0,05 → on rejette H0

Conclusion :

L'âge influence donc significativement la fréquence d'achat, avec une tendance globale décroissante.

► Partie 2.4 : Corrélation entre l'âge et la taille du panier moyen (2 variables quantitatives)



Conclusion :

L'âge influence le panier moyen : les clients jeunes dépensent davantage par achat, tandis que le panier moyen diminue chez les clients plus âgés.

Hypothèses du test

H0 : il n'existe pas de corrélation entre l'âge et la taille du panier moyen

H1 : il existe une corrélation entre l'âge et la taille du panier moyen

Test de Spearman





```
Coefficient de corrélation de Spearman: -0.7746001367053998  
Valeur p: 2.233837973586136e-16
```

Analyse :

Le graphique fait apparaître trois profils :

- moins de 35 ans : panier moyen élevé
- 35 à 55 ans : panier moyen intermédiaire
- plus de 55 ans : panier moyen plus faible

► Partie 2.5 : Lien entre l'âge et la catégorie des livres achetés (variables mixtes)



► Partie 2.5 : Lien entre l'âge et la catégorie des livres achetés (variables mixtes)

Hypothèses du test de normalité :

H0 : les données suivent une distribution normale

H1 : les données ne suivent pas une distribution normale

```
Catégorie : 0
Taille de l'échantillon : 5000
Statistique du test de Shapiro-Wilk : 0.9332318304213082
Valeur p : 1.176093897162146e-42
Les données ne suivent pas une distribution normale : on rejette H0
-----
Catégorie : 1
Taille de l'échantillon : 5000
Statistique du test de Shapiro-Wilk : 0.9882621670580967
Valeur p : 5.554692084174592e-20
Les données ne suivent pas une distribution normale : on rejette H0
-----
Catégorie : 2
Taille de l'échantillon : 5000
Statistique du test de Shapiro-Wilk : 0.6823690142982062
Valeur p : 1.2040579051068622e-70
Les données ne suivent pas une distribution normale : on rejette H0
```

Le test de Shapiro-Wilk indique que la normalité n'est pas respectée dans les trois catégories d'où le choix du test de Kruskal-Wallis

Hypothèses du test de Kruskal-Wallis :

H0 : la distribution de l'âge est la même dans toutes les catégories de livres.

H1 : au moins une catégorie présente une distribution d'âge différente.

```
Statistique de de Kruskal-Wallis: 78458.43837285662
Valeur p: 0.0
```

Analyse :

► Le boxplot montre que la catégorie 2 est associée à des clients plus jeunes que les catégories 0 et 1

► Le test de Kruskal-Wallis confirme que les distributions d'âge diffèrent significativement selon la catégorie achetée

Conclusion :

L'âge des clients n'est pas le même selon les catégories de livres achetés. La catégorie 2 se distingue par une clientèle plus jeune.

Synthèse

- ✓ L'activité est globalement stable, avec un pic fin 2021
- ✓ La catégorie 1 génère le plus de chiffre d'affaires, tandis que la catégorie 2 est la plus chère mais la moins contributrice au CA
- ✓ Les 35–55 ans constituent le cœur de clientèle et portent l'essentiel de l'activité, alors que les moins de 35 ans ont le panier moyen le plus élevé
- ✓ Le CA est en partie concentré sur 4 clients BtoB
- ✓ Les top produits soutiennent fortement le CA, alors que certains flops produits restent peu contributeurs
- ✓ L'âge influence significativement les comportements d'achat

Conclusion et recommandations

- ❖ La catégorie 1 est la plus performante, tandis que la catégorie 2 doit être mieux valorisée pour accroître son volume de ventes
- ❖ Les 35–55 ans sont le segment clé : il faut donc les fidéliser davantage
- ❖ Les moins de 35 ans ont le panier moyen le plus élevé : ils peuvent être ciblés par des offres à plus forte valeur
- ❖ Différencier la gestion des clients BtoB et BtoC permettrait d'optimiser le chiffre d'affaires
- ❖ Renforcer la visibilité des top produits et revoir le positionnement des flop produits