


Projet n°12 :

Détectez des faux billets avec Python

Mission : Concevoir un modèle de Machine Learning capable de distinguer automatiquement les billets authentiques des billets contrefaits à partir de leurs caractéristiques dimensionnelles

Organisation : ONCFM




Contexte :

L'Organisation nationale de lutte contre le faux-monnayage (ONCFM) souhaite automatiser la détection des faux billets. Elle cherche à mettre à la disposition de ses équipes un outil capable d'analyser les dimensions d'un billet et de prédire s'il est vrai ou faux

Objectif :

Développer une application d'apprentissage automatique permettant de prédire la nature d'un billet à partir de ses caractéristiques dimensionnelles



Données : 1 500 billets décrits par 6 mesures dimensionnelles

Algorithmes étudiés : Régression logistique, KNN, Random Forest, K-means




Contexte du projet



Présentation des variables

Dimensions mesurées d'un billet de banque

Variables utilisées dans un projet de détection de contrefaçon



Récapitulatif des variables de dimensions

length	: longueur totale du billet (bord gauche à bord droit)
height_left	: hauteur mesurée sur le côté gauche
height_right	: hauteur mesurée sur le côté droit
diagonal	: diagonale du billet (coin bas gauche à coin haut droit)
margin_up	: marge supérieure (espace blanc au-dessus de la zone imprimée)
margin_low	: marge inférieure (espace blanc au-dessous de la zone imprimée)



is_genuine :

variable cible (vrai / faux billet),
pas une dimension physique

Présentation de la matrice de confusion et des métriques

Matrice de confusion :

	Valeur prédite 0	Valeur prédite 1
Valeur réelle 0	Vrai positif (TP)	Faux négatif (FN)
Valeur réelle 1	Faux positif (FP)	Vrai négatif (TN)

Métrique	Question posée	Calcul / interprétation
Exactitude (Accuracy)	Quelle proportion de billets est correctement classés?	$(TP + TN) / \text{Total}$
Précision – faux billets	Parmi les billets déclarés contrefaits, combien le sont réellement?	$TP / (TP + FP)$
Rappel (Recall) – faux billets	Parmi les billets réellement contrefaits, combien sont détectés?	$TP / (TP + FN)$
F1-score – faux billets	La précision et le rappel sont-ils bien équilibrés ?	$2 \times (\text{Précision} \times \text{Rappel}) / (\text{Précision} + \text{Rappel})$
ROC-AUC	Le modèle distingue-t-il bien les deux classes pour différents seuils ?	0,5 = hasard ; proche de 1 = excellent
Silhouette	Les clusters K-means sont-ils compacts et bien séparés ?	-1 à 1 proche de 0 = clusters qui se chevauchent proche de 1 = meilleure séparation

Démarche et méthodologie d'analyse

Données



Prétraitement



Modélisation



Evaluation



Choix final



Application

1. Analyse exploratoire des données

2. Préparation des données

3. Modélisation (K_means, Régression Logistique, KNN, Random Forest)

4. Évaluation des performances

5. Comparaison des modèles et choix final

6. Utilisation du modèle sur de nouveaux billets

1. Analyse exploratoire des données

- ✓ 1 500 billets décrits par 6 caractéristiques dimensionnelles et une variable cible.
- ✓ 1 000 billets authentiques contre 500 billets contrefaits.
- ✓ 37 valeurs manquantes dans `margin_low`, remplacées par la **médiane**.
- ✓ L'analyse des corrélations a montré que **la longueur** et **les marges** sont les variables les plus informatives pour distinguer les faux billets.

- ❖ 67 % de billets authentiques contre 33 % de billets contrefaits.
- ❖ Les classes sont donc légèrement déséquilibrées, mais les faux billets restent suffisamment représentés pour entraîner et évaluer le modèle.

2. Prétraitement des données

1. Séparation des données en variables explicatives X et variable cible y .

- X : les six caractéristiques dimensionnelles du billet ;
- y : l'authenticité du billet, avec 1 = authentique et 0 = contrefait (classe d'intérêt).

2. Standardisation des variables X afin de les placer sur une échelle comparable. (La standardisation est particulièrement importante pour KNN et K-means, car ces algorithmes reposent sur des calculs de distance. Elle est également utile pour la régression logistique, tandis qu'elle n'est pas nécessaire pour Random Forest. »)

3. Séparation entraînement/test :

- 80 % pour l'entraînement, soit 1 200 billets ;
- 20 % pour le test, soit 300 billets.


4. Conservation de la répartition des classes :

La stratification conserve les proportions initiales (66,7 % de billets authentiques et 33,3 % de billets contrefaits)

Jeu	Authentiques	Contrefaits
Entraînement	800	400
Test	200	100



3. Modélisation

- 
- **K_means**
 - **Régression logistique**
 - **K-nearest neighbors**
 - **Random_forest**
- 
- 

3.1 K-means

Algorithme de clustering **non supervisé** : il regroupe les billets selon leurs ressemblances, il ne connaît pas la classe des billets pendant l'apprentissage.

Principe de fonctionnement :

1. Initialisation de 2 centroïdes provisoires.
2. Chaque billet est affecté au **centroïde le plus proche**.
3. Les centroïdes sont recalculés en prenant la **moyenne** des billets de chaque cluster.
4. Les billets sont à nouveau affectés au centroïde le plus proche.
5. Le processus est répété jusqu'à **stabilisation** des clusters et des centroïdes.


Après l'apprentissage, la variable cible est utilisée uniquement pour interpréter les clusters et les comparer aux classes réelles.

3.1 K-means - résultats

Projection ACP en deux dimensions

Couleur = cluster K-means

Forme = classe réelle



La projection ACP montre que K-Means parvient à séparer les billets en deux groupes proches des classes réelles.

Résultats

✓ Matrice de confusion :

	Prédit contrefait (0)	Prédit authentique (1)
Réel contrefait (0)	98	2
Réel authentique (1)	2	198

- ✓ 4 erreurs
- ✓ Exactitude : 98,67 %
- ✓ Précision des faux billets : 98 %
- ✓ Rappel des faux billets : 98 %
- ✓ F1-score des faux billets : 98 %
- ✓ Score de silhouette : 0,33

❖ Le score de silhouette de 0,33 indique une séparation géométrique modérée des clusters.

3.2 Régression logistique

Algorithme de classification **supervisée** : il construit un modèle mathématique simple et interprétable, permettant d'estimer la probabilité qu'un billet soit authentique ou contrefait.

Principe de fonctionnement :

1. Apprentissage des coefficients à partir des caractéristiques du billet et de la classe réelle.
2. Calcul d'un score en combinant les variables avec leurs coefficients.
3. Transformation du score en probabilité grâce à la fonction logistique.
4. Application du seuil de 0,5 pour classer le billet en authentique ou contrefait.


Probabilité $< 0,5 \rightarrow$ contrefait (0)

probabilité $\geq 0,5 \rightarrow$ authentique (1)

5. Comparaison des prédictions aux classes réelles sur le jeu de test.

3.2 Régression logistique - Résultats

Probabilités prédites avant l'application du seuil de classification



La majorité des probabilités sont proches de 0 ou de 1, ce qui indique que le modèle sépare nettement les deux classes.

Résultats - métriques

✓ Matrice de confusion :

	Prédit contrefait (0)	Prédit authentique (1)
Réel contrefait (0)	98	2
Réel authentique (1)	1	199

- ✓ 3 erreurs
- ✓ Exactitude : 99 %
- ✓ Précision des faux billets : 98,99 %
- ✓ Rappel des faux billets : 98 %
- ✓ F1-score des faux billets : 98,49 %
- ✓ ROC - AUC : 0,9994

3.3 K-nearest neighbors

Algorithme de classification **supervisée** basé sur la proximité entre les observations.

Principe de fonctionnement :

1. Le paramètre K est fixé à 5 dans cette étude. (impair, avec deux classes il y a moins de risque d'égalité dans le vote)
 2. Pour chaque billet du jeu de test, le modèle calcule la distance avec tous les billets du jeu d'entraînement.
 3. Il sélectionne les 5 voisins les plus proches.
 4. Il observe leur classe (authentique ou contrefait) et réalise un vote majoritaire.
 5. La classe majoritaire est attribuée au billet.
- ❖ La prédiction peut devenir plus lente lorsque le volume de données augmente, car les distances sont calculées au moment de la prédiction.

3.3 K-nearest neighbors - Résultats

Matrice de confusion :

	Prédit contrefait (0)	Prédit authentique (1)
Réel contrefait (0)	97	3
Réel authentique (1)	2	198

✓ 5 erreurs

Résultats - métriques

- ✓ Exactitude : 98,33 %
- ✓ Précision des faux billets : 97,98 %
- ✓ Rappel des faux billets : 97 %
- ✓ F1-score des faux billets : 97,49 %
- ✓ ROC - AUC : 0,997

3.4 Random Forest

Algorithme de classification **supervisée** basé sur la combinaison de plusieurs arbres de décision.


Principe de fonctionnement :

1. Création de 100 arbres de décision à partir des données d'entraînement.
2. Chaque arbre apprend automatiquement des seuils de décision sur les variables, par exemple la longueur ou les marges, afin de séparer au mieux les billets authentiques et contrefaits.
3. Pour un nouveau billet, chaque arbre suit ses règles et produit une prédiction.
4. La prédiction finale est obtenue par vote majoritaire des arbres.

Les seuils ne sont pas définis manuellement : ils sont appris automatiquement pendant l'entraînement.

3.4 Random Forest - Résultats

Importance des variables — Random Forest



La longueur (length) et la marge inférieure (margin_low) sont les variables les plus utilisées par Random Forest pour réaliser ses séparations.


Résultats - métriques

✓ Matrice de confusion :

	Prédit contrefait (0)	Prédit authentique (1)
Réel contrefait (0)	98	2
Réel authentique (1)	1	199

- ✓ 3 erreurs
- ✓ Exactitude : 99 %
- ✓ Précision des faux billets : 98,99 %
- ✓ Rappel des faux billets : 98 %
- ✓ F1-score des faux billets : 98,49 %
- ✓ ROC - AUC : 0,9992

4. Comparaison des modèles et choix final



	Modèle	Exactitude	Précision faux	Rappel faux	F1-score faux	ROC-AUC
0	K-means	0.9867	0.9800	0.98	0.9800	NaN
1	Régression logistique	0.9900	0.9899	0.98	0.9849	0.9994
2	KNN	0.9833	0.9798	0.97	0.9749	0.9970
3	Random Forest	0.9900	0.9899	0.98	0.9849	0.9992

Après comparaison, les quatre modèles donnent de très bons résultats. KNN est légèrement moins performant, tandis que K-Means reste un modèle non supervisé.

Les meilleurs résultats sont obtenus par Random Forest et la régression logistique, avec 99 % d'exactitude.

J'ai finalement retenu **la régression logistique**, car elle est plus simple, plus interprétable et possède la meilleure ROC-AUC avec 0,9994. »

5. Utilisation du modèle sur de nouveaux billets

Le modèle retenu est utilisé sur de nouveaux billets afin de prédire automatiquement leur nature : authentique ou contrefait.

Étapes d'utilisation du modèle:

1. Création du pipeline final

Imputation des valeurs manquantes + standardisation + régression logistique

2. Entraînement et sauvegarde du pipeline

3. Création de la fonction de prédiction

La fonction `prediction_billet_RL()` charge le pipeline, vérifie les variables et prépare les données à prédire

4. Chargement des nouveaux billets

5. Prédiction et affichage des résultats

La fonction applique le pipeline et retourne :
0 = Contrefait et 1 = Authentique.

Exemple de résultat :

	diagonal	height_left	height_right	margin_low	margin_up	length	Prédiction	Nature du billet
id								
A_1	171.76	104.01	103.54	5.21	3.30	111.42	0	Contrefait
A_2	171.87	104.17	104.13	6.00	3.31	112.09	0	Contrefait
A_3	172.00	104.58	104.29	4.99	3.39	111.57	0	Contrefait
A_4	172.49	104.55	104.34	4.44	3.03	113.20	1	Authentique
A_5	171.65	103.63	103.56	3.77	3.16	113.33	1	Authentique

Conclusion

La régression logistique a finalement été retenue pour ses excellentes performances, sa simplicité et son interprétabilité : **99 %** d'exactitude, **98 %** de rappel des billets contrefaits et une ROC-AUC de **0,9994**.

Enfin, grâce au pipeline et à la fonction de prédiction, le modèle peut être réutilisé directement sur de nouveaux billets afin de déterminer s'ils sont authentiques ou contrefaits.